Tutorial 2 | Agrupamento de municípios

K-Means e padronização de indicadores · Explicação técnica para o docente

1. Pergunta e desenho de pesquisa

O segundo tutorial utiliza aprendizagem não supervisionada. Ao contrário da classificação, não há um rótulo “correto” previamente atribuído a cada município. O algoritmo procura grupos de observações semelhantes segundo um conjunto explícito de variáveis. A pergunta didática é: municípios com características demográficas e socioeconômicas diferentes podem ser agrupados por perfis?

A unidade de observação é o município fictício. A base tem 36 linhas e duas variáveis numéricas: porcentagem de pessoas com 60 anos ou mais (entre 8% e 30%) e renda média fictícia (entre R$ 1.100 e R$ 3.400). Um terceiro campo identifica cada município. Os valores são sorteados independentemente para facilitar o exercício, de forma que os grupos encontrados não correspondem necessariamente a estruturas populacionais reais.

2. O que cada biblioteca faz

- NumPy: fornece o gerador pseudoaleatório com default_rng e as rotinas necessárias para lidar com vetores; bincount contabiliza quantos municípios foram atribuídos a cada agrupamento.
- pandas: armazena municípios e indicadores em um DataFrame; groupby("grupo") separa registros de acordo com o agrupamento; mean() calcula os indicadores médios de cada grupo.
- scikit-learn / preprocessing: StandardScaler transforma cada variável pela subtração da média e divisão pelo desvio-padrão. Isso reduz a dominância numérica da renda sobre o percentual de idosos.
- scikit-learn / cluster: KMeans identifica centros de grupos e atribui cada município ao centro mais próximo. fit_predict() ajusta o modelo e devolve o número do grupo.
- Matplotlib: scatter() constrói um gráfico de dispersão. Cada ponto representa um município; cada cor corresponde ao grupo encontrado. xlabel(), ylabel() e legend() tornam o gráfico interpretável.

3. Por que padronizar os indicadores

K-Means costuma medir proximidade por distância euclidiana. Sem padronização, diferenças de centenas de reais em renda seriam numericamente muito maiores do que diferenças de poucos pontos percentuais na participação de idosos, podendo dominar as distâncias. A transformação StandardScaler dá a cada variável média aproximadamente zero e desvio-padrão aproximadamente um.

```
z = (x - média_da_variável) / desvio_padrão
```

A padronização não resolve automaticamente o problema substantivo de ponderação entre indicadores. A escolha de renda e envelhecimento já pressupõe que ambas as dimensões são relevantes; ao padronizá-las, o exercício atribui-lhes importância comparável no cálculo de distâncias.

Em trabalhos reais, outras escolhas podem produzir agrupamentos distintos.

4. K-Means: funcionamento do algoritmo

No K-Means, definimos previamente uma quantidade K de grupos. O algoritmo inicializa K centroides e alterna duas operações: (1) atribui cada município ao centro mais próximo e (2) atualiza cada centro pela média dos municípios atribuídos a ele. O procedimento continua até convergir ou atingir seu limite de iterações. O objetivo é reduzir a soma dos quadrados das distâncias dentro dos grupos.

```
Objetivo: minimizar soma_i || x_i - centro_do_grupo_i ||²
Neste notebook: K = 3; n_init = 10; random_state = 42
```

O parâmetro n_init=10 repete a inicialização para reduzir o risco de um resultado ruim decorrente de uma única escolha inicial. random_state=42 torna a execução reproduzível. O número de grupo (por exemplo, 0, 1 ou 2) é somente um identificador, sem hierarquia e sem significado intrínseco.

5. O que o gráfico mostra — e o que não mostra

O eixo horizontal apresenta a participação de idosos, e o vertical a renda média. Cada ponto é um município. Cores iguais indicam proximidade segundo os dados padronizados e o K selecionado. A tabela groupby apresenta os valores médios originais das variáveis em cada grupo, o que auxilia a descrição substantiva dos perfis.

O algoritmo não descobre automaticamente “municípios vulneráveis”. Essa classificação dependeria de uma definição teórica e operacional de vulnerabilidade, seleção adequada de indicadores, direção das associações, justificativa de ponderações e validação contextual. Um grupo pode ser relativamente homogêneo e, ainda assim, não representar uma tipologia estável fora daquela base.

6. Por que experimentar K = 2, 3 e 4

Alterar o número de grupos modifica a resolução analítica. Com dois grupos, os perfis tendem a ser mais amplos; com quatro, podem surgir subdivisões. Não existe motivo para tratar K=3 como verdadeiro apenas porque foi usado inicialmente. Em análises mais completas, medidas como silhueta e estabilidade podem auxiliar, mas a escolha continua dependente do objetivo da pesquisa e da interpretabilidade.

No notebook, o laço sobre K imprime a quantidade de municípios por grupo, não uma medida de qualidade. Dois agrupamentos que tenham o mesmo tamanho podem ter estruturas completamente diferentes. Esse contraste permite explicar por que contagens, gráficos e estatísticas descritivas precisam ser examinados conjuntamente.

7. Orientação de fala para os cinco passos

- Passo 1: contraste aprendizagem supervisionada, que usa um desfecho conhecido, com agrupamento não supervisionado, que usa apenas os indicadores.
- Passo 2: mostre a tabela e identifique a unidade de observação. Pergunte se renda e percentual de idosos são medidos na mesma escala.

- Passo 3: explique a padronização e a escolha de três grupos; mostre que o algoritmo cria uma nova coluna denominada grupo.
- Passo 4: leia o gráfico e as médias dos grupos. Convide os participantes a descrever as diferenças sem atribuir causalidade.
- Passo 5: compare dois, três e quatro grupos e discuta a influência das decisões do pesquisador sobre o resultado.

8. Limitações para pesquisas populacionais

Variáveis aleatórias independentes não representam bem a estrutura socioespacial real dos municípios; o gráfico é apenas demonstrativo. Em pesquisas aplicadas, seria necessário avaliar dependência espacial, comparabilidade temporal, indicadores de desigualdade, população municipal, valores ausentes e possíveis efeitos de escala. Municípios pequenos e grandes aparecem com o mesmo peso no K-Means padrão; isso pode ser inadequado quando se deseja representar populações, e não unidades administrativas.

Perguntas para discussão

- Por que uma variável medida em reais pode dominar uma medida expressa em porcentagem?
- Dois municípios do mesmo grupo são idênticos?
- Quais evidências adicionais seriam necessárias para usar agrupamentos no planejamento de políticas públicas?

Referências para aprofundamento

MacQueen, J. (1967). Some Methods for Classification and Analysis of Multivariate Observations. Proceedings of the Fifth Berkeley Symposium.

Hastie, T.; Tibshirani, R.; Friedman, J. (2009). The Elements of Statistical Learning. Springer.

Documentação oficial: https://scikit-learn.org/stable/modules/clustering.html#k-means e https://scikit-learn.org/stable/modules/preprocessing.html

Correspondência com a prática: tutorial de 30 minutos publicado em cbeluzo.github.io/abep-2026/tutoriais/pratica-2h/. Material explicativo; os dados dos exemplos são sintéticos.